

Cheat-sheet SAD

Paolo Bianchessi

Giugno 2026

Indice

1	Python - blocco import librerie	3
2	Statistica Descrittiva	3
2.1	Tipi di dato	3
2.2	Tipi di Frequenze	3
2.3	Grafici per frequenze	3
2.4	Istogrammi per dati quantitativi continui	4
2.5	Analisi Multivariata	4
2.6	Indici di centralità	4
2.6.1	Media campionaria	4
2.6.2	Mediana campionaria	5
2.6.3	Moda campionaria	5
2.7	Indici di dispersione	5
2.7.1	Varianza campionaria	5
2.7.2	Deviazione standard	5
2.8	Indici di posizione	5
2.9	Box Plot	5
2.10	Regola Empirica	6
2.11	Confronto tra campioni	6
2.12	Covarianza e Correlazione	6
2.13	Eterogeneità	6
2.13.1	Entropia	7
2.14	Concentrazione	7
2.15	Trasformazione dei dati	7
2.16	Alberi di decisione	7
2.17	Analisi dei classificatori	8
2.18	Analisi della varianza	8
3	Calcolo delle Probabilità	9
3.1	Calcolo combinatorio	9
3.2	Teoria degli insiemi	9
3.3	Calcolo delle probabilità	9
3.4	Spazi Equiprobabili	9
3.5	Probabilità Condizionata	10
3.6	Teorema delle probabilità totali	10
3.7	Teorema di Bayes	10
3.8	Eventi indipendenti	10
3.9	Classificatori Naive-Bayes	10
3.10	Variabili Aleatorie	10

3.11	Funzione di Massa di Probabilità	10
3.12	Funzione di Ripartizione - CDF (Discreto)	11
3.13	Valore Atteso (Discreto)	11
3.14	Varianza (Discreto)	11
3.15	V.A. Multivariate	11
3.16	V.A. Indipendenti	11
3.17	Covarianza e Correlazione	12
3.18	Modello di Bernoulli	12
3.19	Modello Binomiale	12
3.20	Modello Ipergeometrico	12
3.21	Modello Uniforme Discreto	13
3.22	Il Modello Geometrico	13
3.23	Il Modello di Poisson	14
3.24	Variabili Aleatorie Continue	14
3.24.1	Le Tre Proprietà di una Densità	14
3.25	Discreto vs Continuo	14
3.26	Valore Atteso e Varianza	15
3.26.1	Formula alternativa per il valore atteso	15
3.27	Indici di Posizione: Moda, Mediana e Quantili	15
3.28	Disuguaglianza di Markov	15
3.29	Disuguaglianza di Chebyshev	15
3.30	Distribuzione Uniforme Continua	16
3.31	Modello Esponenziale	16
3.31.1	Trasformazioni, Minimo e Massimo di Variabili Indipendenti	16
3.31.2	Quantili e Funzione Inversa	17
3.32	Modello Gaussiano Standard	17
3.33	Teorema Centrale del Limite	17
4	Statistica Inferenziale	18
4.1	Stima puntuale	18
4.2	Stimatori Non Distorti	18
4.3	MSE e Consistenza	18
4.3.1	Consistenza in media quadratica:	18
4.4	Media campionaria come stimatore non distorto	18
4.4.1	Dimostrazione della varianza e della consistenza	19
4.5	Metodo Plug-in	19
4.6	Determinazione della Taglia del Campione	19
4.7	Metodo della massima verosimiglianza	20
4.8	Processo di Poisson	20

1 Python - blocco import librerie

```
1 import numpy as np
2 import pandas as pd
3 import matplotlib.pyplot as plt
4 import scipy.stats as st
5 import statsmodels.api as sm
```

2 Statistica Descrittiva

2.1 Tipi di dato

Tipo	Descrizione	Grafico adatto
Dati quantitativi	valori numerici misurabili, gestiti per intervalli - bins	Istogramma <code>s.hist(...)</code>
Dati qualitativi	etichette	A barre/A bastoncini/A torta
Dati qualitativi binari/-booleani	2 categorie	A barre/A bastoncini/A torta
Dati qualitativi nominali	categorie senza ordine	A barre/A bastoncini/A torta
Dati qualitativi ordinali	categorie con ordine	A barre/A bastoncini

2.2 Tipi di Frequenze

Tipo	Descrizione	In Python
Absolute	è difficile capire se un certo valore rappresenta "tanto" o "poco" rispetto al totale.	<code>value_counts()</code> o <code>crosstab</code>
Relative	frazione di volte in cui un valore compare.	<code>normalize=True</code> per i metodi sopra
Cumulate	$\hat{F}(x) = \frac{\#\{x_i \leq x\}}{n} = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(x_i)$	<code>cumsum()</code> su una serie pandas

2.3 Grafici per frequenze

Per qualitativi:

- `plot.bar()`: grafico a barre.
- `plot.pie(...)`: diagramma a torta (aerogramma).
- Parametri utili:
 - `legend=False`,
 - `color=...` (barre/linee),
 - `colors=[...]` (torta),
 - `alpha=...` (trasparenza),
 - `stacked=True` (barre impilate).

Per dati ordinabili/numerici discreti:

- `plt.bar(x, y)` può essere meno adatto se suggerisce intervalli.
- Alternative:
 - `plt.vlines(x, 0, y)` (diagramma a bastoncini),
 - `plt.plot(x, y, 'o')` per evidenziare i punti.

2.4 Istogrammi per dati quantitativi continui

- `s.hist()`: istogramma su intervalli (bin).
- `s.hist(bins=n)`: numero di bin equiampi.
- `s.hist(bins=[...])`: bin personalizzati (anche non equiampi).

Supporto numpy usato:

- `np.arange(start, stop, step)`.
- `np.hstack((a1, a2, ...))` per concatenare array di estremi bin.

Nota: Con bin non equiampi, la lettura corretta passa dall'area delle barre, non solo dall'altezza.

2.5 Analisi Multivariata

Per l'analisi di più variabili:

- **Scatter plot** - analisi correlazione e dispersione

```
1 heroes[heroes['Gender']=='M'].plot.scatter('Height', 'Weight')
2 plt.show()
```

- **Diagramma di Pareto** - frequenze relative e frequenze cumulate

```
1 eye_color = heroes['Eye color']
2 eye_color_freq = eye_color.value_counts(normalize=True)
3
4 eye_color_freq[eye_color_freq>.02].cumsum().plot()
5 eye_color_freq[eye_color_freq>.02].plot.bar()
6 plt.show()
```

- **Partizionamento dei dati** - in pandas `pd.cut`, dividere i dati in sotto-intervalli, ovvero insiemi semi-aperti.

2.6 Indici di centralità

2.6.1 Media campionaria

Formula: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

Proprietà:

- linearità - $y_i = a + bx_i \implies \bar{y} = a + b\bar{x}$
- non robustezza: influenzata da valori estremi

Media ponderata campionaria: Quando i dati hanno frequenze diverse (f_j), si calcola come $\sum f'_j v_j$, dove f'_j sono le frequenze relative.

2.6.2 Mediana campionaria

È il valore che occupa la posizione centrale dopo aver ordinato il campione.

- **Calcolo:**
 - Se n è **dispari**: il valore centrale è $X_{(\frac{n+1}{2})}$.
 - Se n è **pari**: si considerano i due valori centrali.
- A differenza della media, la mediana è più resistente ai valori anomali.

2.6.3 Moda campionaria

- Si applica ad **attributi qualitativi nominali**.
- Rappresenta il valore con la **frequenza massima**. Una distribuzione può avere più valori modali.

2.7 Indici di dispersione

2.7.1 Varianza campionaria

- Si ottiene calcolando la media dei quadrati degli scarti: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
- alternativamente $s^2 = \sum_i X_i^2 - n\bar{X}^2$

Non è lineare:

- $y_i = x_i + b \implies S_y^2 = S_x^2$, sommare una costante non cambia la varianza
- $y_i = ax_i \implies S_y^2 = a^2 S_x^2$

2.7.2 Deviazione standard

- $s = \sqrt{\frac{1}{n-1} \sum_i (x_i - \bar{x})^2}$. È espressa nella stessa unità di misura dei dati!
- $y_i = ax_i \implies s_y = |a|s_x$

2.8 Indici di posizione

Suddividere un campione di dati ordinato in specifiche frazioni.

- Il percentile X_p è quel valore che lascia alla sua sinistra almeno il $p\%$ dei dati e alla sua destra il restante $(100-p)\%$ dei dati.
- La mediana campionaria è il valore che divide i dati lasciando almeno il 50% da una parte e il 50% dall'altra.
- I decili suddividono i dati a scaglioni del 10%, 20%, 30%, ecc..
- I quartili suddividono i dati in blocchi del 25%, 50% e 75%.

2.9 Box Plot

Utile per trovare outliers, criterio $Mediana + 1,5IQR$ (Inter Quartile Range)

In python: `year.plot.box(showfliers=False)`

2.10 Regola Empirica

- Distribuzioni simmetriche/asimmetriche
- **Distribuzione approssimativamente normale** - forma a campana
 - Circa il 68% dei dati si concentra entro una distanza di $\pm 1S_x$ dalla media.
 - Circa il 95% dei dati si trova entro $\pm 2S_x$.
 - Circa il 99% dei dati ricade entro $\pm 3S_x$.

2.11 Confronto tra campioni

Per valutare l'ipotesi che due campioni estratti appartengano alla stessa popolazione:

- **Lo strumento:** Si utilizzano i quantili (ad esempio i decili) e si rappresenta la distribuzione tramite un QQ-plot.
- **Procedimento:** Sul piano cartesiano si disegnano le coppie di punti (x_i, y_i) relative ai due campioni.
- **Interpretazione:** Se i campioni provengono effettivamente dalla stessa popolazione, i punti tenderanno a posizionarsi in modo allineato lungo la bisettrice $y = x$.

2.12 Covarianza e Correlazione

Analizzare se e come due campioni sono collegati

Strumento grafico: scatter plot

Covarianza Campionaria: cattura la relazione tra le variabili analizzando i prodotti degli scarti dalla media.

$$\frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

NB se covarianza = 0, non è detto che non esista relazione tra i campioni

Correlazione di Pearson: È l'indice di correlazione lineare standardizzato, che assume sempre valori nell'intervallo $[-1, 1]$.

- La formula è: $\frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y}) \cdot \frac{1}{s_x s_y}$.

2.13 Eterogeneità

Sfruttando le frequenze relative f .

Indice di Gini calcolato come $I = 1 - \sum_{j=1}^m f_j'^2$, con $0 \leq I \leq 1$.

- **Casi limite:**
 - *Massima Omogeneità (Minima Eterogeneità):* Si ha quando $I = 0$, ovvero quando c'è una sola modalità osservata ($f_k = 1$ e le altre sono 0).
 - *Massima Eterogeneità:* Si ha quando tutte le modalità sono equiprobabili ($f_j = \frac{1}{m}$), in questo caso l'indice vale $\frac{m-1}{m}$.
- **Normalizzazione:** Per confrontare distribuzioni diverse, si divide l'indice per il suo valore massimo teorico, ottenendo $I' = \frac{m}{m-1} I$.

2.13.1 Entropia

Dato un campione $\{a_1, \dots, a_n\}$ in cui occorrono i valori distinti $v_1, \dots, v_s$ e indicando con f_i la frequenza relativa dell'elemento v_i per $i = 1, \dots, s$, la quantità

$$H = \sum_{i=1}^s f_i \log \frac{1}{f_i} = - \sum_{i=1}^s f_i \log f_i$$

è detta *indice di entropia* del campione.

Funzione in python

```
1 def entropy(series):  
2     return sum((series.value_counts(normalize=True)  
3                 .map(lambda f: -f * np.log2(f))))
```

2.14 Concentrazione

La concentrazione analizza come una risorsa suddivisibile (o "ricchezza") è distribuita all'interno di una popolazione i cui membri a_i sono ordinati ($a_1 \leq a_2 \leq \dots \leq a_n$). Inoltre $\bar{a} = \frac{1}{n} \sum_i a_i \implies n\bar{a} = TOT$ "ricchezza".

- **Variabili in gioco:** Si mettono in relazione le frazioni cumulate di popolazione $F_i = \frac{i}{n}$ con le quote cumulate di risorsa $Q_i = \frac{1}{TOT} \sum_{j=1}^i a_j$. $F_i, Q_i \in [0, 1]$
- **Regole base:** Vale sempre la disequazione $Q_i \leq F_i$, e all'ultimo elemento si ha $F_n = Q_n = 1$.
- **Curva di Lorentz:** È il grafico che illustra la concentrazione; più la curva si avvicina alla bisettrice $y = x$, più la concentrazione è vicina al suo minimo (distribuzione equa).
- **Indice di Gini per la Concentrazione:** Si basa sull'Area di concentrazione (data dalla differenza $F_i - Q_i$) e si calcola come $I = \frac{2}{n-1} \sum_{i=1}^{n-1} (F_i - Q_i)$.

2.15 Trasformazione dei dati

A volte è necessario manipolare i dati per facilitare i calcoli o il confronto.

- **Trasformazioni lineari:** Sono funzioni del tipo $f(x) = a + bx$ e permettono di effettuare traslazioni o scalature dei dati (ad esempio normalizzare un valore tra 0 e 1 o tra -1 e 1).
- **Standardizzazione:** È una trasformazione molto comune che consiste nel sottrarre la media e dividere per la deviazione standard: $x' = \frac{x - \bar{x}}{s_x}$.
 - Questa operazione produce una nuova variabile con media nulla ($\bar{x}' = 0$) e deviazione standard unitaria ($s_{x'} = 1$).

2.16 Alberi di decisione

- **Machine learning supervisionato**
- **Logica simile a "indovina chi"** per individuare la classe di appartenenza
- **Bontà della domanda** sfruttando l'indice di eterogeneità/entropia, si cerca di fare domande che dividano i gruppi in modo omogeneo $I = 0$.

2.17 Analisi dei classificatori

Falsi positivi/falsi negativi

- **Il paradosso dell'accuratezza:** Una "elevata accuratezza" non è sempre "sintomo di un buon classificatore", specie se le classi nei dati sono molto sbilanciate.
- **Matrice di confusione e Metriche:** Serve a incrociare l'esito predetto dal classificatore con il valore effettivo reale. I due indici cardine ricavati dal professore sono:
 - **Sensibilità (Sensitivity):** Frazione di positivi riconosciuti, calcolata come $\frac{VP}{TP}$ (Veri Positivi su Totali Positivi).
 - **Specificità (Specificity):** Frazione di negativi riconosciuti, calcolata come $\frac{VN}{TN}$ (Veri Negativi su Totali Negativi).
- **I classificatori estremi:** come il classificatore "CP" (che restituisce sempre Positivo, avendo sensibilità massima e specificità nulla) e il classificatore "CN" (che restituisce sempre Negativo, con specificità massima e sensibilità nulla).
- **Curva ROC:** Visualizza la "traiettoria" delle prestazioni del classificatore. Se la curva giace "sulla diagonale è come lanciare una moneta" (le predizioni sono casuali). "Più l'area sottostante è vicina a 1", più il classificatore è da considerarsi "ideale".

2.18 Analisi della varianza

L'ANOVA (Analysis of Variance) indaga se le medie di un campione "suddiviso in gruppi" appartengono probabilisticamente alla medesima distribuzione originaria.

- **Definizioni di base:** Dato l'individuo i -esimo nel gruppo g -esimo, denotato come X_i^g , per un numero totale di elementi pari a $N = \sum_i n_i$, due riferimenti di media:
 - La media campionaria totale calcolata "fra tutti" gli individui.
 - La media campionaria all'interno dei singoli "gruppi".
 - **Scomposizione della Varianza:** $SS_T = SS_W + SS_B$ esprime che la somma dei quadrati totale (Total Sum of Squares) si divide esattamente nella somma degli scarti "entro" i gruppi (SS_W , Within) e nella somma degli scarti "tra" i gruppi (SS_B , Between).
 - **Il calcolo in Python (Esempio Supereroi):** A lezione il professore ha dimostrato questo teorema confrontando i supereroi Marvel e DC. Tramite `pandas`, vengono isolate le due popolazioni `marvel_strength` e `dc_strength` per verificare se le case editrici dotino i loro personaggi di livelli di forza statisticamente differenti.
-

3 Calcolo delle Probabilità

3.1 Calcolo combinatorio

Permutazioni senza ripetizioni	$P_n = n!$
Permutazioni con ripetizioni	$P_n^r = \frac{n!}{r_1! r_2! \dots r_k!}$
Disposizioni senza ripetizioni	$D_{n,k} = \frac{n!}{(n-k)!} \bigwedge n > k$
Disposizioni con ripetizioni	$D_{n,k}^r = n^k$
Combinazioni senza ripetizioni	$C_{n,k} = \frac{n!}{k! (n-k)!} \bigwedge n > k$
Combinazioni con ripetizioni	$C_{n,k}^r = \frac{(n+k-1)!}{k! (n-1)!}$

3.2 Teoria degli insiemi

- **Spazio campionario** Ω insieme di tutti i possibili eventi
- **Operazioni fondamentali** tra eventi valgono tutte le operazioni base sugli insiemi. Se due eventi intersecati formano l'insieme vuoto, essi sono mutuamente esclusivi.
- **Proprietà algebriche**: commutatività, associatività, distributività, leggi di De Morgan.

3.3 Calcolo delle probabilità

La probabilità di un evento E è un valore numerico $P(E)$ che deve rispettare tre assiomi fondamentali - **Assiomi di Kolmogorov**:

1. $0 \leq P(E) \leq 1$.
2. La probabilità dell'intero spazio campionario è 1: $P(S) = 1$.
3. Data una sequenza di eventi mutuamente esclusivi, la probabilità della loro unione è pari alla somma delle rispettive probabilità singole.

Da questi assiomi si dimostrano svariati teoremi elementari:

- **Probabilità dell'evento complemento**: La probabilità che un evento E non si verifichi è pari a $1 - P(E)$.
- **Probabilità dell'unione**: Dati due eventi qualsiasi E ed F , la probabilità che si verifichi almeno uno dei due è $P(E \cup F) = P(E) + P(F) - P(E \cap F)$.

3.4 Spazi Equiprobabili

Negli spazi in cui tutti gli esiti possibili sono equiprobabili, la definizione classica di probabilità di un evento E appartenente allo spazio campionario Ω è data dal rapporto tra casi favorevoli e casi possibili: $P(E) = \frac{|E|}{|\Omega|}$.

3.5 Probabilità Condizionata

La probabilità condizionata esprime come l'incisione venga "ridotta" o aggiornata quando si acquisiscono nuove informazioni. La formula è:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

3.6 Teorema delle probabilità totali

Quando uno spazio campionario è diviso in partizioni F_i mutuamente esclusive e la cui unione copre l'intero spazio, la probabilità di un evento E si ottiene sommando le sue probabilità parziali all'interno di ogni partizione:

$$P(E) = \sum_{i=1}^n P(E|F_i)P(F_i)$$

3.7 Teorema di Bayes

Il Teorema di Bayes permette di "invertire" la probabilità condizionata ed è formalizzato come:

$$P(F_i|E) = \frac{P(E|F_i)P(F_i)}{\sum_{j=1}^n P(E|F_j)P(F_j)}$$

3.8 Eventi indipendenti

Due eventi E ed F si dicono indipendenti se e solo se la probabilità della loro intersezione è uguale al prodotto delle loro singole probabilità, ovvero $P(E \cap F) = P(E) \cdot P(F)$.

Il concetto di indipendenza è intimamente legato alla probabilità condizionata: sapere che un evento si è verificato non altera in alcun modo la probabilità che si verifichi l'altro.

3.9 Classificatori Naive-Bayes

Si vuole stimare la probabilità di una certa classe a partire dall'evidenza dei dati.

Questa classificazione si basa sul teorema di Bayes: $P(M|N) = P(N|M) \cdot P(M)/P(N)$.

Con una forte assunzione "naive": in quanto assume totale indipendenza tra le feature data la classe target.

3.10 Variabili Aleatorie

Dato $(\Omega, \mathcal{A}, \mathbb{P})$ spazio di probabilità

$$X : \Omega \mapsto \mathbb{R} \quad \omega \in \Omega \text{ quindi } X(\omega) \in \mathbb{R}$$

$$X = \alpha \text{ "scorciatoia" } \{\omega \in \Omega : X(\omega) = \alpha\} \subseteq \Omega$$

3.11 Funzione di Massa di Probabilità

Per V.A. Discrete, definisce la probabilità che X assuma un valore esatto.

- **Definizione:** $\forall x \in \mathbb{R}, p_X(x) = P(X = x)$.
- **Proprietà Fondamentali:**
 1. La probabilità non è mai negativa: $p_X(x) \geq 0$.
 2. La somma di tutte le probabilità nel dominio è pari a 1: $\sum_{x \in D_X} p_X(x) = 1$.

3.12 Funzione di Ripartizione - CDF (Discreto)

Indica la probabilità che la variabile X assuma un valore minore o uguale a un certo x .

- **Definizione:** $F_X(x) = P(X \leq x)$. È una funzione definita come $F_X : \mathbb{R} \rightarrow [0, 1]$.
- **Proprietà Fondamentali:**
 1. I limiti agli estremi sono noti: $\lim_{x \rightarrow +\infty} F_X(x) = 1$.
 2. La funzione è continua da destra.
 3. Per un dominio finito, il grafico assume una forma a gradini ("tratti") costante.

Relazione tra PMF e CDF: Possiamo sempre ricavare la probabilità di un intervallo usando la CDF. Ad esempio, $P(a < X \leq b) = F_X(b) - F_X(a)$. La relazione analitica che le lega è: $F_X(x) = \sum_{y \leq x} p_X(y)$.

3.13 Valore Atteso (Discreto)

- **Formula:** $E[X] = \sum_{x \in D_X} x \cdot P(X = x) = \sum_i x_i \cdot p_X(x_i)$.
- fornisce una misura di tendenza centrale, indicando il valore "medio" che ci si aspetta di ottenere ripetendo l'esperimento molte volte.
- **Operatore lineare** $E[aX + b] = aE[X] + b$
- **Conseguenza** $E[g(X)] = \sum g(x)P(X = x)$

3.14 Varianza (Discreto)

Data X V.A. e $E[X] = \mu$, $Var(X) = E[(X - \mu)^2] \iff E[X^2] - E[X]^2$

Non è lineare: aggiungere una costante non altera la varianza (poiché la dispersione dei dati non cambia), mentre moltiplicare per una costante a scala la varianza per il quadrato di quella costante, portando alla formula $Var(aX + b) = a^2 Var(X)$.

- **Deviazione standard** $\sigma_X = \sqrt{Var(X)}$

3.15 V.A. Multivariate

Spesso si analizza la relazione tra due o più variabili aleatorie congiuntamente, descrivendo il loro comportamento tramite una funzione di distribuzione cumulativa congiunta $F(x, y) = P(X \leq x, Y \leq y)$. Per variabili di questo tipo, un teorema fondamentale dimostra che il valore atteso della somma di variabili aleatorie è uguale alla somma dei loro singoli valori attesi: $E[X + Y] = E[X] + E[Y]$. Questa proprietà è validissima indipendentemente dal fatto che le variabili siano dipendenti o indipendenti tra loro.

3.16 V.A. Indipendenti

Due variabili aleatorie X e Y sono *indipendenti* se, per qualsiasi coppia di insiemi di numeri reali A e B , vale l'equazione $P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B)$.

3.17 Covarianza e Correlazione

Due V.A. X e Y e i rispettivi valori attesi μ_X, μ_Y , la covarianza è definita dal valore atteso degli scarti: $Cov(X, Y) = E((X - \mu_X)(Y - \mu_Y))$.

Proprietà

- **Simmetria** $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, Y) = aCov(X, Y)$
- $Cov(X + b, Y) = Cov(X, Y)$
- $Cov(X, Y) = E[X \cdot Y] - E[X]E[Y]$

3.18 Modello di Bernoulli

- **Definizione:** Una variabile aleatoria $X \sim B(p)$ assume il valore 1 (successo) con probabilità p e il valore 0 (fallimento) con probabilità $1 - p$.
- **Funzione di massa di probabilità:** $p_X(x) = P(X = x) = p^x(1 - p)^{1-x}I_{\{0,1\}}(x)$.
- **Valore Atteso:** $E(X) = \sum_{x=0}^1 x \cdot p_X(x) = 0 \cdot (1 - p) + 1 \cdot p = p$.
- **Varianza:** Calcoliamo prima $E(X^2) = 0^2(1 - p) + 1^2(p) = p$. La varianza è $Var(X) = E(X^2) - [E(X)]^2 = p - p^2 = p(1 - p)$.

3.19 Modello Binomiale

Corrisponde al modello di **estrazione con reimmissione**, dove la probabilità di successo rimane costante a ogni estrazione.

- **Definizione:** $X \sim B(n, p)$ con dominio $D_X = \{0, 1, \dots, n\}$.
- **Funzione di massa di probabilità:** $P(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}$.
- **Valore Atteso:** $E(X) = E(\sum X_i) = \sum E(X_i) = n \cdot p$.
- **Varianza:** Essendo prove indipendenti, la varianza della somma è la somma delle varianze: $Var(X) = \sum Var(X_i) = np(1 - p)$.

3.20 Modello Ipergeometrico

Il modello Ipergeometrico descrive un'estrazione in blocco o **senza reimmissione** da una popolazione finita.

- **Definizione:** Consideriamo una popolazione di $N + M$ oggetti, di cui N funzionanti e M difettosi. Estraiamo n oggetti senza reinserirli. X è il numero di oggetti funzionanti estratti.
- **Funzione di probabilità:**

$$P(X = i) = \frac{\binom{N}{i} \binom{M}{n-i}}{\binom{N+M}{n}}.$$

Questo deriva dal calcolo combinatorio: $\binom{N}{i}$ sono i modi di scegliere i oggetti funzionanti, $\binom{M}{n-i}$ i modi per i difettosi, diviso i casi totali $\binom{N+M}{n}$.

Dimostrazione dei Momenti e Varianza: Come per la Binomiale, $X = \sum_{i=1}^n X_i$ dove X_i indica se l' i -esima estrazione è un successo. Tuttavia, le estrazioni *non* sono indipendenti.

- **Valore Atteso:** $E(X_i) = \frac{N}{N+M} = p$, quindi $E(X) = n \frac{N}{N+M} = np$.
- **Varianza:** A causa della non-indipendenza, entrano in gioco le covarianze:

$$Var(X) = np(1-p) \left(1 - \frac{n-1}{N+M-1} \right)$$

Il termine $(1 - \frac{n-1}{N+M-1})$ è un fattore di correzione per popolazioni finite. Si nota che, per popolazioni infinite ($N+M \rightarrow \infty$), il modello tende a quello Binomiale e la varianza tende a $np(1-p)$.

3.21 Modello Uniforme Discreto

Descrive un fenomeno in cui un numero finito di esiti è ugualmente probabile.

- **Definizione:** $X \sim U(n)$ su uno spazio $\Delta_x = \{1, 2, \dots, n\}$.
- **Funzione di massa:** $P(X = i) = \frac{1}{n}$.
- **Funzione di Ripartizione (CDF):** È una funzione a gradini definita come

$$F_X(x) = \frac{\lfloor x \rfloor}{n} I_{[1,n)}(x) + I_{[n,+\infty)}(x).$$

- **Valore Atteso:** $E(X) = \sum_{i=1}^n i P(X = i) = \frac{1}{n} \sum_{i=1}^n i = \frac{1}{n} \frac{n(n+1)}{2} = \frac{n+1}{2}$.
- **Varianza:** Calcoliamo il momento secondo:

$$E(X^2) = \sum_{i=1}^n i^2 \frac{1}{n} = \frac{1}{n} \frac{n(n+1)(2n+1)}{6} = \frac{(n+1)(2n+1)}{6}$$

Sostituendo nella formula della varianza:

$$Var(X) = \frac{(n+1)(2n+1)}{6} - \frac{(n+1)^2}{4} = \dots = \frac{n^2 - 1}{12}$$

3.22 Il Modello Geometrico

Il modello geometrico descrive il numero di insuccessi che si verificano prima di ottenere il primo successo in una sequenza di prove o esperimenti bernoulliani, che sono indipendenti e identicamente distribuiti.

Essendo focalizzata sugli insuccessi antecedenti al primo successo, la variabile aleatoria X ammette come supporto l'insieme dei numeri naturali includendo lo zero: $D_X = \mathbb{N} \cup \{0\}$.

- **Funzione di massa**

$$p_X(x) = P(X = x) = (1-p)^x p \quad \text{per } x = 0, 1, 2, \dots$$

- **Valore Atteso:** $E[X] = \sum_{i=0}^{\infty} i(1-p)^i p = p \frac{1-p}{p^2} = \frac{1-p}{p}$.
- **Varianza:** Calcolando il momento secondo $E[X^2] = \frac{(1-p)(2-p)}{p^2}$ e applicando la definizione $Var(X) = E[X^2] - E[X]^2$, si ottiene come risultato finale $Var(X) = \frac{1-p}{p^2}$.
- **Funzione di ripartizione** $F_X(x) = 1 - (1-p)^{\lfloor x \rfloor + 1}$
- **Assenza di memoria**

$$P(X \geq s+t | X \geq s) = \frac{P(X \geq s+t)}{P(X \geq s)} = \frac{(1-p)^{s+t}}{(1-p)^s} = (1-p)^t = P(X \geq t)$$

3.23 Il Modello di Poisson

La variabile aleatoria di Poisson modella il numero di occorrenze di determinati eventi nel tempo o nello spazio, e ha grandissime applicazioni in natura in quanto approssima la distribuzione binomiale per eventi rari su larga scala.

- **PMF:** $P(X = i) = e^{-\lambda} \frac{\lambda^i}{i!}$ per $i = 0, 1, 2, \dots$
- **Valore atteso** $E[X] = \lambda$
- **Varianza** $Var(X) = \lambda$
- **CDF** $F_X(k) = e^{-\lambda} \sum_{i=0}^k \frac{\lambda^i}{i!}$
- La distribuzione di Poisson gode della **proprietà di riproducibilità**: se due variabili aleatorie di Poisson indipendenti hanno parametri λ_1 e λ_2 , la loro somma è ancora una Poisson con parametro $\lambda_1 + \lambda_2$.

3.24 Variabili Aleatorie Continue

La densità è definita come la derivata prima della funzione di ripartizione:

$$f_X(x) = F'(x)$$

3.24.1 Le Tre Proprietà di una Densità

Una qualsiasi funzione $f(x)$ rappresenta una valida densità di probabilità su $\mathbb{R}$ se e solo se rispetta tre condizioni:

1. **Non negatività:** $f(x) \geq 0$ per ogni $x \in \mathbb{R}$.
2. **Normalizzazione (Integrale finito):** L'area totale sottesa dalla curva deve essere pari all'evento certo:

$$\int_{-\infty}^{+\infty} f(x) dx = 1$$

3. **Legame con la Ripartizione:**

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f(u) du$$

3.25 Discreto vs Continuo

Concetto	Variabile Aleatoria Discreta	Variabile Aleatoria Continua
Probabilità Puntuale	$P(X = x) = p_X(x) \geq 0$	$P(X = x) = 0$
Probabilità di un Intervallo	$\sum_{x_i \in [a, b]} p_X(x_i)$	$\int_a^b f_X(x) dx$
Valore Atteso $E(X)$	$\sum_{x \in D_X} x p_X(x)$	$\int_{-\infty}^{+\infty} x f_X(x) dx$
Valore Atteso $E(g(X))$	$\sum_{x \in D_X} g(x) p_X(x)$	$\int_{-\infty}^{+\infty} g(x) f_X(x) dx$

3.26 Valore Atteso e Varianza

Il valore atteso nel continuo descrive il baricentro della distribuzione di probabilità:

$$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx$$

Per la Legge dello Statistico Inconsapevole (LOTUS), la media di una trasformazione $g(X)$ si calcola direttamente integrando la funzione rispetto alla densità originale:

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x) f_X(x) dx$$

La **Varianza** mantiene inalterata la sua definizione e la sua formula operativa abbreviata:

$$Var(X) = E((X - E(X))^2) = E(X^2) - (E(X))^2$$

3.26.1 Formula alternativa per il valore atteso

$$E(X) = \int_0^{+\infty} (1 - F_X(x)) dx$$

3.27 Indici di Posizione: Moda, Mediana e Quantili

- **Quantile di livello q :** Fissato un livello di probabilità $q \in (0, 1)$, il quantile x_q è quel valore che accumula esattamente una probabilità q a sinistra:

$$P(X \leq x_q) = q \implies F_X(x_q) = q$$

- **Mediana:** È il quantile di livello $q = 0.5$, ovvero il punto che divide esattamente a metà l'area sottesa dalla densità ($\int_{-\infty}^{\text{mediana}} f(x) dx = \frac{1}{2}$).
- **Moda:** Corrisponde al punto di massimo locale o globale della funzione di densità $f_X(x)$.
- **Proprietà di Simmetria:** Se una curva di densità è perfettamente simmetrica rispetto a un asse verticale, la media e la mediana coincidono esattamente in quel punto di simmetria.

3.28 Disuguaglianza di Markov

- Sia X una variabile aleatoria che assume solo valori non negativi ($X \geq 0$).
- Per qualsiasi costante $a > 0$, vale la seguente disuguaglianza:

$$P(X \geq a) \leq \frac{E(X)}{a}$$

- Passando alla probabilità dell'evento complementare, si ricava la relazione associata:

$$P(X < a) = 1 - P(X \geq a) \geq 1 - \frac{E(X)}{a}$$

3.29 Disuguaglianza di Chebyshev

- Sia X una variabile aleatoria con valore atteso μ e varianza $Var(X) = \sigma^2$.
- Per qualsiasi raggio $r > 0$, la probabilità che lo scarto assoluto tra X e μ sia maggiore o uguale a r è limitata da:

$$P(|X - \mu| \geq r) \leq \frac{\sigma^2}{r^2}$$

- Ponendo lo scarto pari a un multiplo della deviazione standard ($r = k\sigma$ con $k > 0$), si ottiene la forma alternativa:

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$

3.30 Distribuzione Uniforme Continua

- **PDF** $f(x) = \frac{1}{b-a} I_{[a,b]}(x)$, indicata con la notazione $X \sim U([a, b])$.
- **CDF** $F(x) = \frac{x-a}{b-a} I_{[a,b]}(x) + I_{(b,+\infty)}(x)$
- **Valore atteso** $E[X] = \frac{a+b}{2}$
- **Varianza** $Var(X) = \frac{(b-a)^2}{12}$

3.31 Modello Esponenziale

Il modello esponenziale è impiegato per descrivere la durata di funzionamento di sistemi o i tempi di attesa tra eventi governati da un tasso costante.

- Sia $X \sim E(\lambda)$ una variabile aleatoria con parametro di tasso $\lambda > 0$.
- **PDF:** $f_X(x) = \lambda e^{-\lambda x} I_{\mathbb{R}^+}(x)$
- **CDF** $F_X(x) = 1 - e^{-\lambda x} I_{\mathbb{R}^+}(x)$
- **Valore atteso** $E[X] = \frac{1}{\lambda} = \sigma_X$
- **Varianza** $Var(X) = \frac{1}{\lambda^2}$
- **Assenza di memoria** $P(X > s+t | X > s) = P(X > t)$

3.31.1 Trasformazioni, Minimo e Massimo di Variabili Indipendenti

- **Cambio di scala:** Se $X \sim Exp(\lambda)$ e si definisce la variabile $Y = cX$ moltiplicando per una costante $c > 0$, la ripartizione di Y vale:

$$F_Y(x) = P(Y \leq x) = P(cX \leq x) = P(X \leq x/c) = F_X(x/c) = 1 - e^{-\lambda x/c}$$

Ciò prova che Y segue una distribuzione esponenziale con tasso modificato pari a λ/c .

- **Minimo di variabili indipendenti:** Siano $X_1, \dots, X_n$ variabili aleatorie indipendenti, con $X_i \sim Exp(\lambda_i)$. Definendo $Y = \min_{1 \leq i \leq n} X_i$, la probabilità che il minimo superi una soglia x equivale all'intersezione degli eventi di sopravvivenza:

$$P(Y > x) = P\left(\bigcap_{i=1}^n \{X_i > x\}\right) = \prod_{i=1}^n P(X_i > x) = \prod_{i=1}^n e^{-\lambda_i x} = e^{-(\sum_{i=1}^n \lambda_i)x}$$

La ripartizione del minimo è $F_Y(x) = 1 - e^{-\lambda' x}$, dove il tasso complessivo è la somma dei tassi individuali $\lambda' = \sum_{i=1}^n \lambda_i$.

- **Massimo di variabili indipendenti:** Definendo il massimo $Y = \max_{1 \leq i \leq n} X_i$, la sua funzione di ripartizione è data dal prodotto delle singole funzioni di ripartizione:

$$F_Y(x) = P\left(\max_{1 \leq i \leq n} X_i \leq x\right) = P\left(\bigcap_{i=1}^n \{X_i \leq x\}\right) = \prod_{i=1}^n P(X_i \leq x) = \prod_{i=1}^n F_{X_i}(x) = \prod_{i=1}^n (1 - e^{-\lambda_i x})$$

3.31.2 Quantili e Funzione Inversa

- Fissata una probabilità $q \in (0, 1)$, il quantile x_q è definito dall'uguaglianza $P(X \leq x_q) = q = F_X(x_q)$.
- Esplicitando l'equazione $1 - e^{-\lambda x_q} = q$, si ottiene $e^{-\lambda x_q} = 1 - q$, da cui:

$$-\lambda x_q = \ln(1 - q) \implies x_q = -\frac{1}{\lambda} \ln(1 - q)$$

- L'espressione generale della funzione inversa della ripartizione è $F^{-1}(y) = -\frac{1}{\lambda} \ln(1 - y)$.
- In particolare, il calcolo della mediana (corrispondente al quantile $q = 1/2$) fornisce il valore:

$$x_{1/2} = -\frac{1}{\lambda} \ln\left(\frac{1}{2}\right) = \frac{\ln 2}{\lambda}$$

3.32 Modello Gaussiano Standard

La distribuzione Normale (o Gaussiana) è il modello continuo più importante nella statistica e nell'analisi dei dati. La forma più utile e utilizzata analiticamente è la **Distribuzione Normale Standard**, indicata con la notazione $N(0, 1)$.

- **PDF** $f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} = \phi(x)$
- **CDF** $F_X(x) = \Phi(x)$
- **Standardizzazione** $Z \sim N(0, 1) \implies Z = \frac{X - \mu}{\sigma_X}$
- **Teorema De Moivre - Laplace** con un n sufficientemente grande, la distribuzione binomiale $X_n \sim B(n, p) \rightarrow Y_n \sim N(np, \sqrt{np(1-p)})$ converge verso il modello continuo teorico.
- **Riproducibilità** $\forall i = 1, \dots, n \ X_i \sim N(\mu_i, \sigma_i) + \text{indipendenza}$

$$- X = \sum_i X_i \sim N\left(\sum_i \mu_i, \sqrt{\sum_i \sigma_i^2}\right)$$

3.33 Teorema Centrale del Limite

Sia $X_1, X_2, \dots, X_n$ una sequenza di variabili aleatorie i.i.d. ciascuna con media μ e varianza σ^2 allora:

$$\sum_{i=1}^n X_i \sim N(n\mu, \sqrt{n}\sigma) \implies \frac{\sum_i X_i - n\mu}{\sqrt{n}\sigma} \sim N(0, 1)$$

Ancora:

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{\sum_i X_i - n\mu}{\sqrt{n}\sigma} \leq x\right) = \Phi(x)$$

NB in certi casi converge molto in fretta anche per n "piccoli" (circa 30)

4 Statistica Inferenziale

4.1 Stima puntuale

Con l'obiettivo di dedurre le proprietà e trarre conclusioni su una determinata popolazione a partire dall'analisi di un campione osservato. Molto spesso si assume che i valori della popolazione seguano una distribuzione probabilistica F_θ , dipendente da un vettore di parametri ignoti θ .

Il punto di partenza è un **campione**, ovvero un insieme di variabili casuali $X_1, \dots, X_n$ assunte come indipendenti e identicamente distribuite (i.i.d.). L'obiettivo dell'inferenza parametrica puntuale è utilizzare i dati di tale campione per estrapolare un singolo valore numerico che approssimi il parametro θ ignoto. Qualsiasi funzione matematica dei dati campionari utilizzata per questo scopo viene chiamata **stimatore**. Formalmente, uno stimatore è definito come $T = t(X_1, \dots, X_n) = \hat{\theta}$.

4.2 Stimatori Non Distorti

Una delle proprietà fondamentali per valutare la qualità di uno stimatore è la sua **non distorsione**. Uno stimatore T si definisce **non distorto** (o *unbiased*) per il parametro $\tau(\theta)$ se il suo valore atteso coincide esattamente con il parametro stesso per ogni possibile valore di θ :

$$E(T) = \tau(\theta)$$

Quando questa condizione non si verifica, si dice che lo stimatore presenta un **bias** (o distorsione), quantificato dalla differenza tra l'aspettativa dello stimatore e il parametro reale da stimare:

$$b_{\tau(\theta)}(T) = E(T) - \tau(\theta)$$

4.3 MSE e Consistenza

Poiché è irrealistico aspettarsi che uno stimatore restituisca sempre il valore esatto in ogni campione, è necessario misurarne la precisione media, definita come il valore atteso della differenza al quadrato tra lo stimatore e il parametro:

$$MSE_{\tau(\theta)}(T) = E((T - \tau(\theta))^2)$$

Alternativamente:

$$MSE = Var(T) + [b_{\tau(\theta)}(T)]^2$$

4.3.1 Consistenza in media quadratica:

Uno stimatore T si dice **consistente in media quadratica** se, all'aumentare della dimensione del campione n , il suo errore quadratico medio converge a zero:

$$\lim_{n \rightarrow \infty} MSE_{\tau(\theta)}(T) = 0$$

4.4 Media campionaria come stimatore non distorto

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Banale stimatore non distorto, dimostrazione (campione i.i.d, tutte le X_i hanno media μ):

$$E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n}(n\mu) = \mu$$

4.4.1 Dimostrazione della varianza e della consistenza

Assumendo che le variabili X_i siano indipendenti tra loro e possiedano tutte la medesima varianza σ^2 , si ha:

$$\text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} (n\sigma^2) = \frac{\sigma^2}{n}$$

Dal momento che la media campionaria è uno stimatore non distorto, il suo errore quadratico medio equivale proprio alla sua varianza: $MSE = \sigma^2/n$.

Osservando l'andamento del MSE al crescere della dimensione del campione n , possiamo notare che: $\lim_{n \rightarrow \infty} \frac{\sigma^2}{n} = 0$

4.5 Metodo Plug-in

- Sia $X \sim U([0, \theta])$, dove θ è il parametro ignoto.
- Il valore atteso teorico è $E[X] = \frac{\theta}{2}$.
- Usando la media campionaria $\bar{X}$ per stimare la media teorica, otteniamo l'uguaglianza $\bar{X} = \frac{\theta}{2}$.
- Invertendo la formula, otteniamo uno stimatore plug-in per il parametro: $T = 2\bar{X}$.
- Verifichiamo la non distorsione di questo stimatore: $E[2\bar{X}] = 2E[\bar{X}] = 2\left(\frac{\theta}{2}\right) = \theta$. Lo stimatore è corretto.

L'MSE di questo stimatore (essendo non distorto, coincide con la sua varianza) sarà:

$$\text{Var}(2\bar{X}) = 4\text{Var}(\bar{X}) = 4 \frac{\text{Var}(X)}{n} = \frac{4\theta^2}{12n} = \frac{\theta^2}{3n}.$$

4.6 Determinazione della Taglia del Campione

Il problema della determinazione della taglia del campione consiste nel trovare il numero minimo di osservazioni n affinché la media campionaria $\bar{X}$ approssimi la media reale della popolazione μ con un errore massimo ϵ e un livello di confidenza $1 - \delta$.

Dimostrazione della taglia con TCL:

Richiediamo che la probabilità che l'errore sia compreso in ϵ sia almeno $1 - \delta$:

$$P(-\epsilon \leq \bar{X} - \mu \leq \epsilon) \geq 1 - \delta$$

Standardizzando i termini, dividiamo per l'errore standard $\frac{\sigma}{\sqrt{n}}$:

$$P\left(-\frac{\epsilon\sqrt{n}}{\sigma} \leq Z \leq \frac{\epsilon\sqrt{n}}{\sigma}\right) \approx 2\Phi\left(\frac{\epsilon\sqrt{n}}{\sigma}\right) - 1 \geq 1 - \delta$$

Isolando la funzione di ripartizione della normale standard Φ :

$$\Phi\left(\frac{\epsilon\sqrt{n}}{\sigma}\right) \geq 1 - \frac{\delta}{2}$$

Applicando la funzione inversa Φ^{-1} :

$$\frac{\epsilon\sqrt{n}}{\sigma} \geq \Phi^{-1}\left(1 - \frac{\delta}{2}\right) \implies n \geq \left(\frac{\sigma}{\epsilon} \Phi^{-1}\left(1 - \frac{\delta}{2}\right)\right)^2$$

Quando si implementano simulazioni computazionali o si generano grafici come i QQ plot in Python per valutare se una distribuzione cumulativa (CDF) ricorda una curva normale, il Teorema del Limite Centrale è la base matematica che giustifica la normalità del campione all'aumentare dei dati raccolti.

4.7 Metodo della massima verosimiglianza

- **Campione** $X_1, X_2, \dots, X_n$ i.i.d. (come X)
- **Funzione di verosimiglianza**

$$l(\theta) = l(\theta; x_1, x_2, \dots, x_n) = f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i; \theta) = \prod_{i=1}^n f_X(x_i; \theta)$$

- **Per ottenere lo stimatore**, si cerca la derivata di $l(\theta)$

$$\hat{\theta} = \arg \max_{\theta} l(\theta) = \arg \max_{\theta} \ln l(\theta)$$

4.8 Processo di Poisson

Sia $N(t)$ il numero di eventi accaduti nell'intervallo di tempo da 0 a t . Questo sistema è un *Processo di Poisson* con tasso λ se obbedisce ai seguenti assiomi:

1. $N(0) = 0$
 2. **Incrementi indipendenti:** Il numero di eventi che si verificano in intervalli di tempo non sovrapposti sono tra loro indipendenti.
 3. **Incrementi stazionari:** La probabilità che si verifichi un certo numero di eventi in un intervallo dipende solo dalla lunghezza dell'intervallo, non dal suo posizionamento nel tempo.
 4. In un tempo infinitesimale h , la probabilità di osservare esattamente 1 evento è circa λh .
 5. Nello stesso tempo infinitesimale h , la probabilità di osservare 2 o più eventi è circa 0.
- **Proposizione** Partendo dagli assiomi, si dimostra che il numero totale di eventi in qualsiasi intervallo lungo t segue una classica distribuzione di Poisson con media λt :

$$P\{N(t) = k\} = e^{-\lambda t} \frac{(\lambda t)^k}{k!}, \quad k = 0, 1, \dots$$

- **I Tempi di Interarrivo** Chiamiamo X_1 il tempo trascorso fino al primo evento, e X_n il tempo trascorso tra l'evento $(n-1)$ -esimo e l'evento n -esimo. Si dimostra che i "tempi di interarrivo" $X_1, X_2, \dots$ sono variabili aleatorie **indipendenti** e ciascuna di esse segue una **distribuzione esponenziale con media $1/\lambda$** .

